

DiffMM: Mô Hình Khuếch Tán Đa Phương Thức cho Hệ Thống Gợi Ý

Yangqin Jiang Lianghao Xia Wei Wei Da Luo Kangyi Lin Chao Huang*

Đại học Hồng Kông, Trung Quốc | WeChat, Tencent, Quảng Châu, Trung Quốc

*Chao Huang là tác giả liên lạc · MM '24, 28/10-01/11/2024, Melbourne, VIC, Úc · <https://doi.org/10.1145/3664647.3681498>

Tóm tắt

Sự phát triển của các nền tảng chia sẻ đa phương thức trực tuyến như TikTok và YouTube đã tạo điều kiện để hệ thống gợi ý cá nhân hóa tích hợp nhiều phương thức (trực quan, văn bản và âm thanh) vào biểu diễn người dùng. Đồng thời, giải quyết thách thức về độ thưa thớt dữ liệu vẫn là vấn đề then chốt. Nghiên cứu gần đây đã giới thiệu học tự giám sát để cải thiện hệ thống gợi ý. Tuy nhiên, các phương pháp này thường dựa trên phép tăng cường ngẫu nhiên đơn giản hoặc thông tin liên quan từ các góc nhìn trực quan, có thể đưa vào nhiễu không liên quan và không thể căn chỉnh chính xác ngữ cảnh đa phương thức với mô hình hóa tương tác người dùng-mục. Để lấp đầy khoảng cách nghiên cứu này, chúng tôi đề xuất mô hình khuếch tán đồ thị đa phương thức mới cho hệ thống gợi ý, gọi là DiffMM. Khung đề xuất tích hợp mô hình khuếch tán đồ thị nhận thức phương thức với mô hình học đối chiếu xuyên phương thức nhằm cải thiện học biểu diễn người dùng nhận thức phương thức, căn chỉnh tốt hơn thông tin đặc trưng đa phương thức với mô hình hóa quan hệ cộng tác. Phương pháp của chúng tôi tận dụng khả năng sinh của mô hình khuếch tán để tự động tạo ra đồ thị người dùng-mục nhận thức các phương thức khác nhau. Chúng tôi thực hiện các thí nghiệm toàn diện trên ba bộ dữ liệu công khai, chứng minh sự vượt trội của DiffMM. Mã nguồn: <https://github.com/HKUDS/DiffMM>.

Từ khóa: Hệ thống gợi ý, Mô hình khuếch tán, Đa phương thức

1 Giới Thiệu

Các hệ thống gợi ý đa phương tiện là không thể thiếu trong thương mại điện tử và các ứng dụng chia sẻ nội dung liên quan đến lượng lớn nội dung web đa phương tiện, bao gồm video ngắn, hình ảnh và âm nhạc [17]. Các hệ thống này xử lý nhiều phương thức của nội dung mục, như đặc trưng trực quan, âm thanh và văn bản của các mục [21], giúp nắm bắt sở thích người dùng ở mức độ chi tiết theo từng phương thức.

Một số hướng nghiên cứu đã nổi lên để tích hợp nội dung đa phương thức vào gợi ý đa phương tiện. VBPR mở rộng khung phân tích ma trận để xử lý đặc trưng phương thức của mục [7]. ACF [2] giới thiệu mạng chú ý phân cấp để xác định sở thích người dùng ở cấp độ thành phần. Gần đây hơn, MMGCN [31], GRCN [30] và LATTICE [37] sử dụng Mạng nơ-ron đồ thị (GNN) để kết hợp thông tin

phương thức vào quá trình truyền thông điệp. Tuy nhiên, hầu hết các hệ thống gợi ý đa phương tiện hiện có đều phụ thuộc vào dữ liệu nhãn chất lượng cao (tức là tương tác người dùng quan sát được) để huấn luyện có giám sát [13, 32]. Trong thực tế, tương tác thừa thớt so với toàn bộ không gian tương tác, khiến các mô hình có giám sát khó tạo ra những chính xác biểu diễn sở thích phức tạp.

Rút cảm hứng từ thành công gần đây của học tự giám sát (SSL) cho tăng cường dữ liệu, một hướng tiếp cận hứa hẹn để giải quyết vấn đề thừa thớt dữ liệu là tạo tín hiệu giám sát từ dữ liệu không nhãn. Tuy nhiên, SGL [32], NCL [13] và HCCF [33] cố gắng kết hợp SSL vào lọc cộng tác mà không điều chỉnh lược đồ tăng cường cho nhiệm vụ gợi ý đa phương tiện cụ thể. Chẳng hạn, SGL dùng nhiễu ngẫu nhiên để bỏ nút và cạnh, trong khi NCL và HCCF tập trung khám phá tương quan ngữ nghĩa ẩn. Đáng tiếc, các phương pháp này bỏ qua tầm quan trọng của đặc tính đa phương thức trong tăng cường dữ liệu, hạn chế biểu diễn sở thích người dùng nhận thức phương thức.

Để thu hẹp khoảng cách này, CLCRec [29] và MMSSL [25] làm giàu những mục bằng đặc trưng đa phương thức qua SSL dựa trên thông tin tương hỗ. Tương tự, MMGCL [35] và SLMRec [20] đưa nhiễu ngẫu nhiên vào đặc trưng phương thức cho học đối chiếu. Tuy nhiên, các phương pháp này thường dựa vào tăng cường ngẫu nhiên đơn giản hoặc căn chỉnh đồ thị liên góc nhìn trực quan, có thể đưa vào thông tin nhiễu không liên quan. Do đó, cần có một mô hình tăng cường nhận thức phương thức thích ứng để tự giám sát chính xác hơn.

Đóng góp. Trước những hạn chế của các giải pháp hiện tại, chúng tôi đề xuất phương pháp mới gọi là Mô hình Khuếch tán Đồ thị Đa phương thức cho Hệ thống Gợi ý (DiffMM). Lấy cảm hứng từ tiến bộ gần đây trong Mô hình Khuếch tán (DM) [5, 9] cho tổng hợp ảnh [19], phương pháp của chúng tôi tập trung tạo ra đồ thị người dùng-mục nhận thức phương thức bằng sức mạnh sinh của mô hình khuếch tán. Điều này cho phép chuyển giao hiệu quả kiến thức đa phương thức vào mô hình hóa tương tác người dùng-mục. Cụ thể, chúng tôi sử dụng quá trình làm hồng từng bước để dần dần đưa nhiễu ngẫu nhiên vào đồ thị tương tác ban đầu. Sau đó, thông qua quá trình đảo ngược, chúng tôi lập lại khôi phục đồ thị đã bị làm hồng để thu cấu trúc đồ thị gốc. Để hướng dẫn quá trình đảo ngược và tạo ra đồ thị nhận thức phương thức,

chúng tôi giới thiệu cơ chế tiêm tín hiệu nhận thức phương thức (MSI) đơn giản nhưng hiệu quả.

Tóm lại, bài báo này có những đóng góp sau:

- Chúng tôi trình bày DiffMM, hệ thống gợi ý đa phương thức mới tập trung cải thiện sự cân chỉnh giữa ngữ cảnh đa phương thức và mô hình hóa tương tác người dùng-mục. Phương pháp tận dụng học tự giám sát thích ứng theo phương thức kết hợp với sức mạnh sinh của mô hình khuếch tán.
- Chúng tôi sử dụng quá trình làm hồng từng bước và đảo ngược, được hướng dẫn bởi cơ chế MSI, để chuyển giao kiến thức đa phương thức vào mô hình hóa tương tác người dùng-mục. Ngoài ra, biểu diễn trong DiffMM được tăng cường bởi tín hiệu tự giám sát từ học đối chiếu xuyên phương thức.
- Các thí nghiệm toàn diện trên nhiều bộ dữ liệu chuẩn xác nhận hiệu quả của DiffMM, thể hiện cải thiện hiệu suất đáng kể so với các mô hình cơ sở cạnh tranh.

2 Phương Pháp

2.1 Kiến Thức Cơ Bản

Đồ thị cộng tác với đặc trưng đa phương thức. Dựa trên thành công của các kỹ thuật lọc cộng tác dựa trên GNN, DiffMM sử dụng hiệu quả dữ liệu có cấu trúc đồ thị để cung cấp hệ thống gợi ý đa phương thức toàn diện. Chúng tôi mô hình hóa tương tác người dùng-mục trong đồ thị $G = \{(u, i) \mid u \in U, i \in I\}$, trong đó U và I là tập hợp người dùng và mục. Một cạnh (u, i) cho biết người dùng u đã tương tác với mục i . Để làm giàu đồ thị G với các phương thức đa dạng, bao gồm đặc trưng văn bản, trực quan và âm thanh, chúng tôi giới thiệu các vectơ đặc trưng theo phương thức $F_i = \{f_i^1, \dots, f_i^M\}$ cho mỗi mục i . Mỗi vectơ $f_i^m \in \mathbb{R}^d$ chứa đặc trưng phương thức m cho mục i , thuộc tập phương thức M .

Xây dựng bài toán. Mục tiêu là phát triển hệ thống gợi ý đa phương thức nắm bắt hiệu quả quan hệ người dùng-mục trong khi xem xét đặc trưng đa phương thức. Chúng tôi muốn học hàm f dự đoán khả năng người dùng u tương tác với mục i dựa trên đồ thị tương tác đa phương thức $G^M = (G, \{F_i \mid i \in I\})$, biểu diễn là $\hat{y}_{ui} = f(G^M)$.

2.2 Mô Hình Khuếch Tán Đồ Thị Đa Phương Thức

Được thúc đẩy bởi thành công của mô hình khuếch tán trong việc bảo tồn các mẫu dữ liệu thiết yếu trong đầu ra được tạo ra [9], khung DiffMM đề xuất hướng tiếp cận mới cho hệ thống gợi ý đa phương thức. Cụ thể, chúng tôi giới thiệu mô-đun khuếch tán đồ thị đa phương thức để tạo ra các đồ thị tương tác người dùng-mục kết hợp thông tin phương thức, từ đó cải thiện mô hình hóa sở thích người dùng. Khung tập trung giải quyết tác động tiêu cực của đặc trưng phương thức không liên quan hoặc nhiễu trong

hệ thống gợi ý đa phương tiện. Chúng tôi hợp nhất tín hiệu cộng tác người dùng-mục với thông tin đa phương thức bằng mô hình xác suất khuếch tán khử nhiễu nhận thức phương thức.

2.2.1 Mô Hình Xác Suất Khuếch Tán với Tương Tác

Quá trình khuếch tán đồ thị tiến. Chúng tôi xét người dùng u với các tương tác trên tập mục I , ký hiệu là $\alpha_u = [\alpha_u^0, \alpha_u^1, \dots, \alpha_u^{|I|-1}]$, trong đó $\alpha_u^i = 1$ hoặc 0 cho biết người dùng u có tương tác với mục i hay không. Quá trình tiến xây dựng $\alpha_{1:T}$ trong chuỗi Markov bằng cách dần dần đưa vào nhiễu Gaussian qua T bước. Bước chuyển từ α_{t-1} sang α_t được tham số hóa như sau:

$$q(\alpha_t \mid \alpha_{t-1}) = N(\alpha_t; \sqrt{(1-\beta_t)} \cdot \alpha_{t-1}, \beta_t I) \quad (1)$$

Quy mô nhiễu Gaussian tại mỗi bước t được kiểm soát bởi $\beta_t \in (0, 1)$. Khi $T \rightarrow \infty$, α_T hội tụ về phân phối Gaussian chuẩn. Sử dụng thủ thuật tái tham số hóa và tính cộng tính của nhiễu Gaussian độc lập, ta trực tiếp thu được α_t từ α_0 :

$$q(\alpha_t \mid \alpha_0) = N(\alpha_t; \sqrt{\gamma_t} \cdot \alpha_0, (1-\gamma_t)I) \quad (2)$$

Để điều chỉnh lượng nhiễu thêm vào $\alpha_{1:T}$, chúng tôi đưa vào các tham số $\gamma_t = 1 - \beta_t$ và $\bar{\gamma}_t = \prod_{\tau=1}^t \gamma_\tau$. Chúng tôi tái tham số hóa $\alpha_t = \sqrt{\gamma_t} \cdot \alpha_0 + \sqrt{(1-\gamma_t)} \cdot \epsilon$, với $\epsilon \sim N(0, I)$. Bộ lập lịch nhiễu tuyến tính cho $1 - \bar{\gamma}_t$:

$$1 - \bar{\gamma}_t = s \cdot [\gamma_{\min} + (t-1)/(T-1) \cdot (\gamma_{\max} - \gamma_{\min})], t \in \{1, \dots, T\} \quad (3)$$

Quá trình khuếch tán đồ thị đảo ngược. DiffMM nhằm loại bỏ nhiễu từ α_t và khôi phục α_{t-1} trong bước đảo ngược. Quá trình đảo ngược được mô hình hóa như sau:

$$p_\theta(\alpha_{t-1} \mid \alpha_t) = N(\alpha_{t-1}; \mu_\theta(\alpha_t, t), \Sigma_\theta(\alpha_t, t)) \quad (4)$$

2.2.2 Tối Ưu Hóa Nhận Thức Phương Thức cho Khuếch Tán

Huấn luyện khuếch tán đồ thị. Mục tiêu là hướng dẫn quá trình khuếch tán đồ thị đảo ngược. Giới hạn dưới của bằng chứng (ELBO) của log-likelihood âm của tương tác quan sát α_0 cần được tối ưu hóa:

$$\mathcal{L}_{\text{elbo}} = E_{q(\alpha_0)}[-\log p_\theta(\alpha_0)] \leq \sum_{t=0}^T E_q[\mathcal{L}_t] \quad (5)$$

Huấn luyện mô hình khử nhiễu. Chúng tôi sử dụng mạng nơ-ron để thực hiện khử nhiễu trong quá trình đảo ngược. Mục tiêu của $\mathcal{L}_t$ là buộc $p_\theta(\alpha_{t-1} \mid \alpha_t)$ xấp xỉ phân phối có thể tính được $q(\alpha_{t-1} \mid \alpha_t, \alpha_0)$ thông qua phân kỳ KL. Qua quy tắc Bayes ta có dạng đóng:

$$q(\alpha_{t-1} \mid \alpha_t, \alpha_0) \propto N(\alpha_{t-1}; \tilde{\mu}(\alpha_t, \alpha_0, t), \sigma^2(t)I) \quad (7)$$

Tổn thất khớp khử nhiễu $\mathcal{L}_t$ tại bước t được rút gọn thành:

$$\mathcal{L}_t = (1/2\sigma^2(t)) \cdot \|\mu_\theta(\alpha_t, t) - \tilde{\mu}(\alpha_t, \alpha_0, t)\|_2^2 \quad (9)$$

Tiêm tín hiệu nhận thức phương thức (MSI). Mục tiêu của khuếch tán đồ thị đa phương thức là cải thiện hệ thống gợi ý bằng đồ thị người dùng-mục nhận thức phương thức. Chúng tôi thiết kế cơ chế MSI, hướng dẫn mô-đun khuếch tán tạo ra nhiễu đồ thị người dùng-mục với các

phương thức tương ứng. Cụ thể, chúng tôi tổng hợp đặc trưng phương thức mục căn chỉnh e_m^i với xác suất tương tác nhận thức phương thức được dự đoán $\hat{\alpha}_0$. Tổn thất MSE cho phương thức m:

$$L_{msi}^m = \|\hat{\alpha}_0 \cdot e_m^i - \alpha_0 \cdot e_m^i\|_2^2 \quad (14)$$

2.2.3 Suy Luận của Mô Hình Khuếch Tán Đồ Thị Đa Phương Thức

Chúng tôi thiết kế chiến lược suy luận đơn giản căn chỉnh với huấn luyện khuếch tán cho dự đoán tương tác người dùng-mục. Cụ thể, đầu tiên làm hồng $\alpha_0 \rightarrow \alpha_1 \rightarrow \dots \rightarrow \alpha_T$ qua T' bước trong quá trình tiến, sau đó đặt $\hat{\alpha}_T = \alpha_T$ để thực hiện khử nhiễu đảo ngược $\hat{\alpha}_T \rightarrow \hat{\alpha}_{T-1} \rightarrow \dots \rightarrow \hat{\alpha}_0$ qua T bước. Cuối cùng, chúng tôi dùng $\hat{\alpha}_0$ để tái xây dựng cấu trúc đồ thị người dùng-mục. Đồ thị người dùng-mục kết quả cho phương thức m được ký hiệu là A^m .

2.3 Tăng Cường Đối Chiếu Xuyên Phương Thức

Trong các tình huống gợi ý đa phương thức, có mức độ nhất định của sự nhất quán trong các mẫu tương tác người dùng qua các phương thức mục khác nhau (trực quan, văn bản và âm thanh). Chẳng hạn, đặc trưng trực quan và âm thanh của video ngắn có thể cùng thu hút người dùng xem, nên sở thích trực quan và âm thanh của người dùng có thể đan xen theo cách phức tạp. Để nắm bắt sự nhất quán liên quan đến phương thức này, chúng tôi thiết kế hai mô hình học đối chiếu nhận thức phương thức dựa trên các mô neo khác nhau.

2.3.1 Góc Nhìn Đối Chiếu Nhận Thức Phương Thức

Chúng tôi áp dụng phương pháp học biểu diễn dựa trên GNN, cụ thể là tổng hợp thông tin trên đồ thị người dùng-mục nhận thức phương thức A^m . Đặc trưng phương thức mục căn chỉnh theo chiều $e_m^i \in \mathbb{R}^d$ được tính từ vectơ đặc trưng thô $f^m \in \mathbb{R}^{d_m}$:

$$e_m^i = \text{Norm}(\text{Trans}(f^m)), m \in M \quad (15)$$

Sau đó, chúng tôi thực hiện tổng hợp thông tin với nhúng người dùng $E^u \in \mathbb{R}^{U \times d}$ và đặc trưng phương thức mục $F_m^i \in \mathbb{R}^{I \times d}$, để thu nhúng nhận thức phương thức $z^m \in \mathbb{R}^d$:

$$z_u^m = \bar{A}_{u,i}^m \cdot E^u, z_i^m = \bar{A}_{u,i}^m \cdot F_m^i, \bar{A}_{u,i}^m = \frac{A_{u,i}^m}{\sqrt{|N_u^m|} \sqrt{|N_i^m|}} \quad (16)$$

Để khám phá hiệu ứng cộng tác bậc cao nhận thức đa phương thức, chúng tôi tiếp tục thực hiện truyền thông điệp lặp trên đồ thị tương tác gốc A bởi:

$$z_{l+1}^m = \bar{A} \cdot z_l^m, z_0^m = z^m \quad (17)$$

2.3.2 Tăng Cường Đối Chiếu Nhận Thức Phương Thức

Góc nhìn phương thức làm mô neo. Dựa trên tương quan mẫu hành vi người dùng qua các phương thức khác nhau, chúng tôi coi nhúng từ các phương thức khác nhau là các góc nhìn và sử dụng hàm mất mát InfoNCE để tối đa hóa thông tin tương hỗ giữa hai góc nhìn phương thức:

$$L_{cl}^{user} = \sum_{m1 \in M} \sum_{m2 \in M} \sum_{u \in U} -\log [\exp(s(\bar{z}_{u,1}^{m1}, \bar{z}_{u,2}^{m2})/\tau) / \sum_{v \in U} \exp(s(\bar{z}_{u,1}^{m1}, \bar{z}_{v,2}^{m2})/\tau)] \quad (18)$$

Góc nhìn chính làm mô neo. Phương pháp học đối chiếu thứ hai tận dụng mẫu hành vi người dùng qua các phương thức khác nhau để hướng dẫn và cải thiện học nhiệm vụ gợi ý mục tiêu. Chúng tôi sử dụng nhúng H từ nhiệm vụ chính làm mô neo và tối đa hóa thông tin tương hỗ với các góc nhìn phương thức bằng InfoNCE. Kết hợp hai tổn thất đối chiếu: $L_{cl} = L_{cl}^{user} + L_{cl}^{item}$.

2.4 Tổng Hợp Đồ Thị Đa Phương Thức

Để tạo ra biểu diễn cuối cùng $\bar{h}_u, \bar{h}_i \in \mathbb{R}^d$, chúng tôi đầu tiên tổng hợp tất cả nhúng nhận thức phương thức f^m và đồ thị người dùng-mục nhận thức phương thức A^m tương ứng. Sau đó, chúng tôi thực hiện truyền thông điệp trên đồ thị tương tác gốc A để khám phá tín hiệu cộng tác bậc cao. Với nhúng đơn phương thức z^m , chúng tôi tổng hợp biểu diễn của từng phương thức bằng cách cộng có trọng số, sử dụng các vectơ tham số hóa học được κ_m :

$$h_u = \sum_{m \in M} \kappa_m \cdot z_u^m, h_i = \sum_{m \in M} \kappa_m \cdot z_i^m \quad (21)$$

Tiếp theo, chúng tôi thực hiện truyền thông điệp trên $\bar{A}$ bằng GNN để khám phá tín hiệu cộng tác bậc cao:

$$H_{l+1} = \bar{A} \cdot H_l, H_0 = h_u \text{ hoặc } h_i \quad (22)$$

Cuối cùng, nhúng theo từng lớp được tổng hợp qua sum-pooling để tạo nhúng cuối cùng $H = \sum_{l=0}^L H_l + \omega \cdot \text{Norm}(H_0)$, trong đó ω là siêu tham số kiểm soát trọng số của $\text{Norm}(H_0)$ nhằm giảm thiểu vấn đề làm mịn quá mức. DiffMM dự đoán tương tác qua $\hat{y}_{u,i} = \bar{h}_u^T \cdot \bar{h}_i$.

2.5 Huấn Luyện Mô Hình Đa Nhiệm Vụ

Quá trình huấn luyện DiffMM gồm hai phần: huấn luyện cho nhiệm vụ gợi ý và cho mô-đun khuếch tán đồ thị đa phương thức. Tổn thất cho tối ưu hóa mô-đun khuếch tán của phương thức m:

$$L_{dm}^m = L_{elbo} + \lambda_0 \cdot L_{msi}^m \quad (24)$$

Với nhiệm vụ gợi ý, chúng tôi sử dụng tổn thất BPR cùng tổn thất đối chiếu L_{cl} :

$$L_{bpr} = \sum_{(u,i,j) \in O} -\log \sigma(\hat{y}_{ui} - \hat{y}_{uj}) \quad (25)$$

$$L_{rec} = L_{bpr} + \lambda_1 \cdot L_{cl} + \lambda_2 \cdot \|\Theta\|_2^2 \quad (26)$$

3 Đánh Giá

Trong phần này, chúng tôi trình bày kết quả thực nghiệm để xác nhận hiệu quả của DiffMM. Chúng tôi giải quyết các câu hỏi nghiên cứu (RQ) sau:

- RQ1: Mô hình đề xuất hoạt động như thế nào so với các hệ thống tiên tiến nhất?
- RQ2: Đóng góp của các thành phần chính là gì đối với hiệu suất tổng thể?
- RQ3: DiffMM giải quyết vấn đề thừa thớt trong hệ thống gợi ý đến mức nào?

- RQ4: Các siêu tham số khác nhau ảnh hưởng đến kết quả như thế nào?
- RQ5: Tăng cường khuếch tán mang lại cải thiện như thế nào so với ngẫu nhiên?
- RQ6: Học quan hệ người dùng-mục nâng cao khả năng diễn giải gợi ý như thế nào?

3.1 Thiết Lập Thục Nghiệm

Bộ dữ liệu đánh giá. Chúng tôi đánh giá mô hình trên ba bộ dữ liệu gợi ý đa phương thức công khai: TikTok, Amazon-Baby và Amazon-Sports.

Giao thức đánh giá. Chúng tôi sử dụng ba chỉ số phổ biến: Recall@K, Precision@K và NDCG@K. Theo phương pháp của các nghiên cứu trước [28, 30], chúng tôi áp dụng chiến lược đánh giá tất cả mục theo thứ hạng (all-rank).

Mô hình cơ sở. Chúng tôi so sánh DiffMM với nhiều mô hình cơ sở, bao gồm: MF-BPR [18], NGCF [23], LightGCN [8], DiffRec [22], SGL [32], NCL [13], HCCF [33], VBPR [7], LightGCN-M, DiffRec-M, MMGCN [31], GRCN [30], LATTICE [37], CLCRec [29], MMGCL [35], SLMRec [20], LightGT [27] và BM3 [38].

3.2 So Sánh Hiệu Suất (RQ1)

Bảng 1 trình bày kết quả đánh giá so sánh hiệu suất. DiffMM được in đậm và mô hình cơ sở tốt nhất được gạch chân. Kết quả cho thấy một số quan sát chính:

- Sự vượt trội của DiffMM. Phương pháp của chúng tôi liên tục vượt trội tất cả mô hình cơ sở trên các bộ dữ liệu khác nhau. Lợi thế này đến từ việc sử dụng hiệu quả thông tin đa phương thức thông qua học đối chiếu xuyên phương thức với tăng cường khuếch tán nhận thức phương thức.
- Hiệu quả tăng cường dữ liệu xuyên phương thức. SGL, NCL và HCCF chỉ đạt cải thiện biên so với NGCF và LightGCN do bỏ qua thông tin đa phương thức. DiffMM tận dụng thông tin đa phương thức, cho phép trích xuất tín hiệu tự giám sát nhận thức phương thức bổ sung cho nhiệm vụ gợi ý đa phương thức.
- Hiệu quả khuếch tán đồ thị đa phương thức. MMGCL và SLMRec vẫn có hạn chế: che trực tiếp đặc trưng phương thức trong MMGCL có thể mất thông tin quan trọng. DiffMM nổi bật bằng cách sử dụng mô hình khuếch tán đồ thị đa phương thức để xây dựng đồ thị người dùng-mục nhận thức phương thức.

Bảng 1: So sánh hiệu suất trên TikTok, Amazon theo Recall@20, Precision@20, NDCG@20. Kết quả tốt nhất được in đậm, mô hình cơ sở tốt nhất được gạch chân.

Bộ dữ liệu	Chỉ số	MF-BPR	LightGCN	LATTICE	BM3	DiffMM
TikTok (3 dòng)	Recall	0.0346	0.0653	0.0843	0.0957	0.1129
	Prec	0.0017	0.0033	0.0042	0.0048	0.0056
	NDCG	0.0130	0.0282	0.0367	0.0404	0.0456

Bộ dữ liệu	Chỉ số	MF-BPR	LightGCN	LATTICE	BM3	DiffMM
Amazon Baby	Recall	0.0440	0.0698	0.0829	0.0839	0.0975
	Prec	0.0024	0.0037	0.0044	0.0044	0.0051
	NDCG	0.0200	0.0319	0.0368	0.0361	0.0411
Amazon Sports	Recall	0.0430	0.0782	0.0915	0.0975	0.1017
	Prec	0.0023	0.0042	0.0048	0.0051	0.0054
	NDCG	0.0202	0.0369	0.0424	0.0442	0.0458

3.3 Kiểm Tra Phân Rã Mô Hình (RQ2)

Để xác nhận hiệu quả của các phương pháp, chúng tôi loại bỏ riêng lẻ ba thành phần chính: học đối chiếu xuyên phương thức (w/o CL), mô hình khuếch tán đồ thị đa phương thức (w/o DM) và tiềm tín hiệu nhận thức phương thức (w/o MSI). Với biến thể w/o DM, chúng tôi thay thế mô hình khuếch tán bằng VGAE. Kết luận chính:

- Biến thể w/o CL cho thấy sự suy giảm đáng chú ý về hiệu suất trên tất cả trường hợp, xác nhận hiệu quả của việc kết hợp tín hiệu tự giám sát bổ sung thông qua đặc trưng đa phương thức.
- Biến thể w/o DM, khi thay mô hình khuếch tán bằng VGAE, cho thấy sự cải thiện đáng kể, xác nhận tính vượt trội của mô hình khuếch tán so với VGAE trong việc tạo đồ thị người dùng-mục nhận thức phương thức.
- Biến thể w/o MSI cũng cho thấy sự suy giảm, nhấn mạnh vai trò quan trọng của MSI trong việc hỗ trợ mô-đun khuếch tán tạo ra đồ thị nhận thức phương thức.

3.4 Xử Lý Dữ Liệu Tương Tác Thừa Thót (RQ3)

Chúng tôi điều tra hiệu quả của DiffMM trong xử lý dữ liệu tương tác người dùng-mục thừa thót trên các bộ dữ liệu con với mức độ thừa thót khác nhau của Amazon-Baby. DiffMM liên tục vượt trội tất cả mô hình cơ sở, đặc biệt với các nhóm người dùng thừa thót hơn. Chúng tôi quy lợi thế này cho hướng tiếp cận học đối chiếu xuyên phương thức với đồ thị người dùng-mục nhận thức phương thức được tạo ra bởi DiffMM, giúp tận dụng tín hiệu tự giám sát chất lượng cao để giảm thiểu tác động tiêu cực của độ thừa thót dữ liệu.

3.5 Phân Tích Mô Hình Chuyên Sâu (RQ4)

Chúng tôi điều tra độ nhạy của các siêu tham số quan trọng trong DiffMM:

- Ảnh hưởng của λ_0 trong mô hình khuếch tán đồ thị. Siêu tham số λ_0 xác định sức mạnh của MSI. Hiệu suất tối ưu đạt được bằng cách sử dụng các giá trị λ_0 khác nhau cho các bộ dữ liệu cụ thể, nhấn mạnh tầm quan trọng của việc chọn λ_0 phù hợp.
- Tác động của ω trong tổng hợp đồ thị đa phương thức. Giá trị ω nhỏ (ví dụ 0.10) gây phụ thuộc nặng vào tổng hợp thông tin bậc cao, có thể gây làm mịn quá mức. Giá trị ω lớn (ví dụ 1.00) bỏ qua thông tin bậc cao, dẫn đến hiệu suất kém. Cần chọn ω cân bằng để

đạt hiệu suất tối ưu.

- Tác động của τ và λ_1 trong tăng cường dữ liệu xuyên phương thức. Hệ số nhiệt độ τ và trọng số InfoNCE λ_1 có tầm quan trọng thiết yếu. Sử dụng các giá trị khác nhau của τ và λ_1 cho các bộ dữ liệu tương ứng đạt được hiệu suất tốt nhất.

3.6 Hiệu Quả Tăng Cường Khuếch Tán Đồ Thị (RQ5)

Để đánh giá hiệu quả của tăng cường khuếch tán đồ thị, chúng tôi thực hiện phân tích toàn diện trên Amazon-Baby và Amazon-Sports bằng cách kiểm tra ảnh hưởng của tỷ lệ hợp nhất giữa đồ thị người dùng-mục nhận thức phương thức (DiffMM) và đồ thị được tăng cường ngẫu nhiên (loại bỏ cạnh). Tỷ lệ hợp nhất 0 chỉ sử dụng đồ thị nhận thức phương thức; tỷ lệ 1 sử dụng hoàn toàn tăng cường ngẫu nhiên. Kết quả rõ ràng: với cả hai bộ dữ liệu, tỷ lệ hợp nhất tăng dần đến suy giảm hiệu suất, nhấn mạnh tính vượt trội của mô hình khuếch tán đồ thị nhận thức phương thức so với tăng cường ngẫu nhiên.

4 Công Trình Liên Quan

4.1 Hệ Thống Gợi Ý Tăng Cường SSL

Học tự giám sát (SSL) đã nổi lên như giải pháp hiệu quả cho vấn đề thừa thớt dữ liệu trong hệ thống gợi ý [10, 13]. Trong tăng cường đồ thị với học đối chiếu, SGL [32], NCL [13] và HCCF [33] tạo tín hiệu SSL bằng cách đối chiếu các cặp nút dương qua kỹ thuật loại bỏ ngẫu nhiên nút/cạnh và nhận dạng hàng xóm ngữ nghĩa. Công việc gần đây trong tăng cường chuỗi dựa trên SSL bao gồm CL4SRec [34] và ICL [4], tận dụng kỹ thuật cắt xén, che giấu và sắp xếp lại để làm phong phú chuỗi mục.

4.2 Phương Pháp Gợi Ý Đa Phương Thức

Việc kết hợp ngữ cảnh đa phương thức là trọng tâm trong nâng cao hệ thống gợi ý [1, 14, 26]. VBPR [7] mở rộng phân tích ma trận bằng cách tích hợp những mục với đặc trưng đa phương thức. Các mô hình dựa trên chú ý như ACF [2] và VECF [3] nắm bắt sở thích người dùng phức tạp qua nội dung đa phương thức. MMGCN [31] và GRCN [30] chứng minh hiệu quả của việc tận dụng cấu trúc dữ liệu để mô hình hóa các phụ thuộc bậc cao phức tạp.

4.3 Mô Hình Sinh cho Hệ Thống Gợi Ý

Hệ thống gợi ý đã có tiến bộ đáng kể nhờ các mô hình sinh, đặc biệt là GAN [6, 25] và VAE [12, 16]. Mô hình khuếch tán gần đây đã đạt được kết quả trong hệ thống gợi ý, mang lại ổn định và biểu diễn tốt hơn [15, 22, 24]. Một số hướng tiếp cận mô hình hóa quá trình khuếch tán bằng cách nắm bắt phân phối xác suất tương tác [22], trong khi những hướng khác tập trung vào quá trình khuếch tán ở cấp độ nhúng [15]. CDDRec [24] giới thiệu mô hình khuếch tán khứu nhiều có điều kiện mới tạo ra biểu diễn chất lượng cao, tránh vấn đề sụp đổ. DiffKG [11] cho phép học đồ thị tri thức mạnh mẽ với mô hình khuếch

tán.

5 Kết Luận

Chúng tôi giới thiệu DiffMM, mô hình gợi ý đa phương thức mới làm phong phú mô hình xác suất khuếch tán bằng cách kết hợp nhận thức phương thức. Phương pháp của chúng tôi sử dụng mô hình khuếch tán đồ thị đa phương thức để tái tạo đồ thị người dùng-mục toàn diện, trong khi tận dụng lợi thế của mô-đun tăng cường dữ liệu xuyên phương thức cung cấp tín hiệu tự giám sát có giá trị. Kết quả thực nghiệm toàn diện xác nhận rõ ràng sự vượt trội của phương pháp về hiệu suất gợi ý. Hướng phát triển trong tương lai, kế hoạch của chúng tôi là tích hợp các mô hình ngôn ngữ lớn để hướng dẫn quá trình khuếch tán với khả năng hiểu ngữ nghĩa mạnh mẽ, từ đó cho phép tăng cường thông tin hơn.

Tài Liệu Tham Khảo

- [1] Xianshuai Cao et al. Cross-modal knowledge graph contrastive learning for machine learning method recommendation. MM, 2022.
- [2] Jingyuan Chen et al. Attentive collaborative filtering: Multimedia recommendation with item-and component-level attention. SIGIR, 2017.
- [3] Xu Chen et al. Personalized fashion recommendation with visual explanations based on multimodal attention network. SIGIR, 2019.
- [4] Yongjun Chen et al. Intent contrastive learning for sequential recommendation. WWW, 2022.
- [5] Florinel-Alin Croitoru et al. Diffusion models in vision: A survey. TPAMI, 2023.
- [6] Min Gao et al. Recommender systems based on generative adversarial networks. Information Sciences, 2021.
- [7] Ruining He and Julian McAuley. VBPR: visual bayesian personalized ranking from implicit feedback. AAAI, 2016.
- [8] Xiangnan He et al. LightGCN: Simplifying and powering graph convolution network for recommendation. SIGIR, 2020.
- [9] Jonathan Ho, Ajay Jain, Pieter Abbeel. Denoising diffusion probabilistic models. NeurIPS, 2020.
- [10] Yangqin Jiang et al. Adaptive graph contrastive learning for recommendation. KDD, 2023.
- [11] Yangqin Jiang et al. DiffKG: Knowledge Graph Diffusion Model for Recommendation. arXiv:2312.16890, 2023.
- [12] Dawen Liang et al. Variational autoencoders for collaborative filtering. WWW, 2018.
- [13] Zihan Lin et al. Improving graph collaborative filtering with neighborhood-enriched contrastive learning. WWW, 2022.
- [14] Fan Liu et al. Disentangled multimodal representation learning for recommendation. TMM, 2022.
- [15] Qidong Liu et al. Diffusion Augmentation for Sequential Recommendation. CIKM, 2023.
- [16] Jianxin Ma et al. Learning disentangled representations for recommendation. NeurIPS, 2019.
- [17] Ruihong Qiu et al. Causalrec: Causal inference for visual debiasing. MM, 2021.

- [18] Steffen Rendle et al. BPR: Bayesian personalized ranking from implicit feedback. UAI, 2009.
- [19] Robin Rombach et al. High-resolution image synthesis with latent diffusion models. CVPR, 2022.
- [20] Zhulin Tao et al. Self-supervised learning for multimedia recommendation. TMM, 2022.
- [21] Di Wang et al. Online collective matrix factorization hashing for large-scale cross-media retrieval. SIGIR, 2020.
- [22] Wenjie Wang et al. Diffusion Recommender Model. arXiv:2304.04971, 2023.
- [23] Xiang Wang et al. Neural graph collaborative filtering. SIGIR, 2019.
- [24] Yu Wang et al. Conditional Denoising Diffusion for Sequential Recommendation. arXiv:2304.11433, 2023.
- [25] Wei Wei et al. Multi-Modal Self-Supervised Learning for Recommendation. WWW, 2023.
- [26] Wei Wei et al. PromptMM: Multi-Modal Knowledge Distillation for Recommendation. arXiv:2402.17188, 2024.
- [27] Yinwei Wei et al. LightGT: A light graph transformer for multimedia recommendation. SIGIR, 2023.
- [28] Yinwei Wei et al. Hierarchical user intent graph network for multimedia recommendation. TMM, 2021.
- [29] Yinwei Wei et al. Contrastive learning for cold-start recommendation. MM, 2021.
- [30] Yinwei Wei et al. Graph-refined convolutional network for multimedia recommendation. MM, 2020.
- [31] Yinwei Wei et al. MMGCN: Multi-modal graph convolution network for personalized recommendation. MM, 2019.
- [32] Jiancan Wu et al. Self-supervised graph learning for recommendation. SIGIR, 2021.
- [33] Lianghao Xia et al. Hypergraph contrastive collaborative filtering. SIGIR, 2022.
- [34] Xu Xie et al. Contrastive learning for sequential recommendation. ICDE, 2022.
- [35] Zixuan Yi et al. Multi-modal graph contrastive learning for micro-video recommendation. SIGIR, 2022.
- [36] Junliang Yu et al. Self-supervised multi-channel hypergraph convolutional network for social recommendation. WWW, 2021.
- [37] Jinghao Zhang et al. Mining latent structures for multimedia recommendation. MM, 2021.
- [38] Xin Zhou et al. Bootstrap latent representations for multimodal recommendation. WWW, 2023.